## Коллекции Java

Коллекции или контейнеры — это классы позволяющий хранить и производить операции над множеством объектов. Коллекции используются для сохранения, получения, манипулирования данными и обеспечивают агрегацию одних объектов другими.

Во многих языках программирования (Java, C, C++, Pascal) единственным встроенным в язык средством хранения объектов являются массивы. Однако, массивы обладают значительными недостатками, одним из них является конечный размер массива, как следствие необходимость следить за размером массива. Другим - индексная адресация, что не всегда удобно, т.к. ограничивает возможности добавления и удаления объектов. Чтобы избавиться от этих недостатков уже несколько десятилетий программисты используют рекурсивные типы данных, такие как списки и деревья. Стандартный набор коллекций Java служит для избавления программиста от необходимости самостоятельно реализовывать эти типы данных и снабжает его дополнительными возможностями.

До выхода Java 2 v1.5 Tiger коллекции обладали значительным недостатком по сравнению с массивами. Дело в том что до версии 1.5 Java не поддерживал настраиваемые типы данных, что не позволяло создавать типизированные коллекции. С введением в Java 2 v1.5 настраиваемых (generics) типов Collections Framework был переписан и сейчас поддерживает строгую типизацию. Т.е. можно объявить коллекцию, которая сможет хранить объекты только определенного класса и потомков этого класса.

В данной статье будут рассмотрены основные классы и интерфейсы Collections Framework в однозадачной среде. Т.е. в ней не будут рассмотрены вопросы синхронизации коллекции и коллекции специально созданные для работы в многозадачной среде, которые находятся в пакете java.util.concurrent.\*.

# Интерфейсы

Интерфейсы в Collections Framework играют ключевую роль. Все классы коллекций унаследованы от различных интерфейсов, которые определяют поведение коллекции. Иными словами интерфейс определяет «что делает коллекция», а конкретная реализация «как коллекция делает то что определяет интерфейс».

При разработке приложений рекомендуется, там где это возможного, использовать интерфейсы. Такая организация позволяет легко заменять реализацию интерфейса, с целью повышения производительности, например. А так же позволяет разработчику сконцентрироваться на задаче, а не на особенностях реализации.

Как не трудно догадаться, первая задача которая встает перед разработчиком при использовании Collections Framework – это выбор интерфейса. К выбору интерфейса следует подходить исходя из предметной области. Например, если в реальном мире Вы имеете дело с очередью на обслуживание, вполне вероятно, что Вам необходимо использовать интерфейс Queue<E>.

Рассмотрим интерфейсы подробнее:

Iterable<T>

Интерфейс Iterable<T> означает то что данная коллекция может формировать объект-итератор $^1$ , а значит может быть использована в конструкции for (в виде for-each) $^2$ 

Collection<E>

<sup>1</sup> Итераторы используются для последовательного обхода всех элементов коллекции.

<sup>2</sup> Использовать конструкцию for в виде for-each стало возможным начиная с Java 2 v1.5 Tiger

Это базовый интерфейс Collections Framework. В интерфейсе Collection<E> определены основные методы для манипуляции с данными, такие как вставка (add, addAll), удаление (remove, removeAll, clear), поиск (contains). Однако, в конкретной реализации часть методов может быть не определена, а их использование, в этом случае, вызовет исключение UnsupportedOperationException. Поэтому я бы рекомендовал использовать интерфейс более адекватно описывающий предметную область.

#### Интерфейсы наследующие интерфейс Collection<E>:

List<E>

Интерфейс List<E> служит для описания списков. Данный интерфейс определяет поведение коллекций, которые служат для хранения упорядоченного набора объектов. Порядок в котором хранятся элементы определяется порядком их добавления в список. Коллекции, реализующие интерфейс List<E> могут хранить 1,2 и более копий одного и того же объекта (ссылки на объект). Определена операция получения части списка. А в классе Collections определен метод для сортировки списков.

Peaлизации: ArrayList<E>, LinkedList<E>.

Oueue<E>

Реализует FIFO – буфер. Позволяет добавлять и получать объекты. При этом объекты могут быть получены в том порядке, в котором они были добавлены.

Peaлизации: ArrayDeque<E>, LinkedList<E>.

Deque<E>

Hаследует Queue<E>. Двунаправленная очередь. Позволяет добавлять и удалять объекты с двух концов. Так же может быть использован в качестве стека.

Peaлизации: ArrayDeque<E>, LinkedList<E>.

Set<E>

Коллекции, наследующие интерфейс Set<E> обеспечивают уникальность хранимых объектов. Иными словами, один и тот же объект не может быть добавлен более одного раза. При использовании данного интерфейса крайне желательно переопределить метод equals хранимых объектов, т.к. он используется для определения уникальности объектов<sup>3</sup>.

Peaлизации: HashSet<E>, LinkedHashSet<E>, TreeSet<E>.

SortedSet<E>

Наследует Set<E>. Реализации этого интерфейса, помимо того что следят за уникальностью хранимых объектов, поддерживают их в порядке возрастания. Отношение порядка между объектами может быть определено, как с помощью метода compareTo интерфейса Comparable<T>, так и при помощи специального класса наследующего интерфейс Comparator<T>.

Peaлизации: TreeSet<E>.

#### Отображения:

Map < K, V >

Класс Мар<К, V> используется для отображения каждого элемента из одного множества объектов (ключей) на другое (значений). При этом каждому элементу из

<sup>3</sup> Не всегда. Например в коллекции TreeSet для определения уникальности используется метод сомратеТо. Большое спасибо Евгению Матюшкину aka Skipy (<a href="http://www.skipy.ru/">http://www.skipy.ru/</a>).

множества ключей ставится в соответствие 1 элемент из множества значений. В то же время одному элементу из множества значений может соответствовать 1, 2 и более элементов из множества ключей. Интерфейс Map<K, V> описывает функциональность ассоциативных массивов

```
SortedMap<K, V>
```

Hаследует Map<K, V>. Реализации этого интерфейса обеспечивают хранение элементов множества ключей в порядке возрастания (см. SortedSet<E>).

Реализации: TreeMap<K, V>.

### Реализации

Как видно Collections API обеспечивает богатый выбор интерфейсов, практически на любой случай. Однако эти интерфейсы всего лишь описание того что класс коллекции должен делать. Интерфейсы не говорят о том как тот или иной класс коллекции реализует свой интерфейс. Более того, различные реализации могут накладывать дополнительные ограничения.

#### Общие вопросы хранения данных

Для начала разберемся каким образом классы Collections API хранят данные. Если вы посмотрите на список реализаций интерфейса List<E>, например, то увидите десять его реализаций<sup>4</sup>. Возникает резонный вопрос: неужели существует 10 способов хранения списков? Вовсе нет. Все способы хранения данных в Collections Framework можно свести трем основным: массивы, связанные списки, бинарные деревья. Рассмотрим их подробнее.

Массивы – один из старейших способов хранения данных. Суть в том что данные помещаются последовательно в специально отведенную для этого область памяти. Данные в массиве должны быть одного типа, а значит и размера. Это позволяет легко узнать адрес в памяти по которому хранится нужные элемент, а следовательно и время обращения к произвольному элементу массива постоянное<sup>5</sup>. Напомню, что в массивах Java объекты не хранятся, хранятся лишь указатели на объекты. Контейнеры на основе массивов самостоятельно следят за размером массива. Когда массив исчерпывается создается новый, как правило размер нового массива в два раба больше чем старого. Контейнеры обеспечивают дополнительные функции поиска и доступа к элементам массива, например создание итератора. Так же на основе массива реализованы хэш-таблицы, о которых мы поговорим позже.

Контейнеры на основе массивов: ArrayList<E>, ArrayDeque<E>.

Связанные списки представляют собой цепочку из объектов ссылающихся друг на друга. Рассмотри звено $^6$  такой цепочки из реализации LinkedList<E>:

```
private static class Entry<E> {
E element;
Entry<E> next;
Entry<E> previous;
```

<sup>4</sup> В версии Java 2 v1.6 Mustang

<sup>5</sup> На самом деле не всегда. Если массив очень большой, то скорость доступа к массиву будет зависеть от того попадает ли искомый элемент в кэш, находится ли он в реальной памяти ЭВМ или страница на которой он находится выгружена на жесткий диск.

<sup>6</sup> Обычно звено называют элементом списка. Здесь использовано слово звено с тем чтобы не вносить путаницу, т.к. элементом будет называться объект хранящийся в списке.

}

Как видно, одно звено содержит ссылки на предыдущее и следующее звенья, а так же на объект, хранящийся в списке. Реализация LinkedList<E> представляет собой замкнутый двунаправленный список. Скорость доступа к произвольному элементу будет зависеть от его положения относительно головы списка (того звена на которое ссылается объект LinkedList<E>) и в среднем будет пропорциональна размеру списка. Однако, скорость последовательного доступа ко всем элементам списка посредством итератора не будет зависеть от положения элементов в списке. Отсюда можно заключить, что контейнеры на основе связанных списков не стоит использовать там где необходимо часто обращаться к произвольному элементу.

Контейнеры на основе связанных списков: LinkedList<E>.

Бинарные деревья служат для хранения и поиска упорядоченных объектов. Это значит, что для хранимых объектов необходимо определить отношение порядка при помощи метода сомрагеТо и наследования от интерфейса Comparable<T> или класса реализующего интерфейс Comparator<T>. Скорость доступа к произвольному объекту в таких деревьях пропорциональна логарифму размера контейнера.

Контейнеры на основе бинарных деревьев: TreeSet<E>, TreeMap<K, V>.

Хэш-таблицы — контейнеры на основе массивов в которых для поиска элемента в массиве используется не индекс элемента в массиве, а его хэш-функция. Как известно для любого объекта в Java реализована хэш-функция и рекомендуется переопределять ее всегда, а для объектов-сущностей в обязательном порядке. В хэш-таблицах индекс определяется на основе хэш-функции, а в нужной позиции массива хранится указатель на связанный список элементов у которых хэш-функции совпадают. Как не трудно догадаться скорость доступа будет меньше тогда, когда связанные списки хэш-таблицы будут как можно короче, иными словами, когда хэш-функции различных объектов не будут совпадать.

Kонтейнеры на основе хэш-таблиц: HashSet<E>, HashMap<K,V>, WeakHashMap<K,V>.